R-programmering för dataanalys

Presenterad av:
Henri
Irene
Kevin
Anarkoli

E-handel dataanalys

Ansvarig:
Henri - Dataförståelse

Case och syfte

Detta projekt analyserar orderdata från ett **e-handelsföretag** i syfte att **ge ledningen ett bättre beslutsunderlag**.
Vår fokus är identifiera konkreta mönster i datan som företaget kan använda för att minska **returer** och **förbättra kundupplevelsen.**

Valda frågor

Valda frågor

1. Hur skiljer sig returgraden mellan olika kategorier, regioner och kundtyper?
2. Finns det ett samband mellan lång leveranstid och fler returer?
3. Påverkar rabatter hur mycket som returneras?

Motivering:
Frågorna är viktiga eftersom många returer kan bli dyrt för företaget och påverka lönsamheten. Genom att undersöka skillnader mellan kategorier, regioner och kundtyper kan företaget se var problemen finns och vad som kan förbättras. Det är också viktigt att titta på om långa leveranstider leder till fler returer, eftersom det kan påverka både kundnöjdhet och kostnader. Till sist är det bra att undersöka om rabatter påverkar returgraden, eftersom rabatter ibland kan leda till fler impulsköp och därmed fler returer

Datasetet

Datasetet innehåller 1000 rader och 16 kolumner med både numeriska och kategoriska variabler samt en datumvariabel.

Några variabler har saknade värden, bland annat campaign_source, discount_pct, payment_method, shipping_days och city.

För analysen aspekter relaterade till returgrad fokuserar vi främst på variablerna

- returned,
- shipping_days,
- discount_pct,
- product_category, region samt customer_type för jämförelser mellan olika grupper

Datastädning och förberedelse

Standardisering

Kolumnerna standardiserades för att säkerställa att datan var konsekvent:

- Textfält rensades från mellanslag och versaler standardiserades
- *city* korrigerades för att undvika dubbletter
- *returned* omvandlades till numerisk form (0/1)
- Säkerställde att kolumner hade korrekt format genom att konvertera *order_date* till datum samt *quantity* och *shipping_days* till int

Hantering av saknade värden

- Kategoriska variabler fylldes med vanligaste värdet
- Numeriska variabler erstattes med medianen

Medianen valdes för att den är robust mot extremvärden. Andelen saknade värden var låg och detta bevarar så mycket information som möjligt.

Skapande av nya variabler

- **Nivåer för leveranstid** (Fast (1-2d), Medium (3-4d), Slow (6-9d)
- **Nivåer för rabatt** (No discount, Low (1-10%), Medium (11-25%), High (25%+)

Möjliggör gruppjämförelser och tydligare visualiseringar.

Ansvarig:
Irene - Datastädning och förberedelse

Ansvariga:
Kevin - Statistiska sammanfattningar
Anarkoli - Visualisering

Hur skiljer sig returgrad mellan olika kategorier, regioner eller kundtyper?

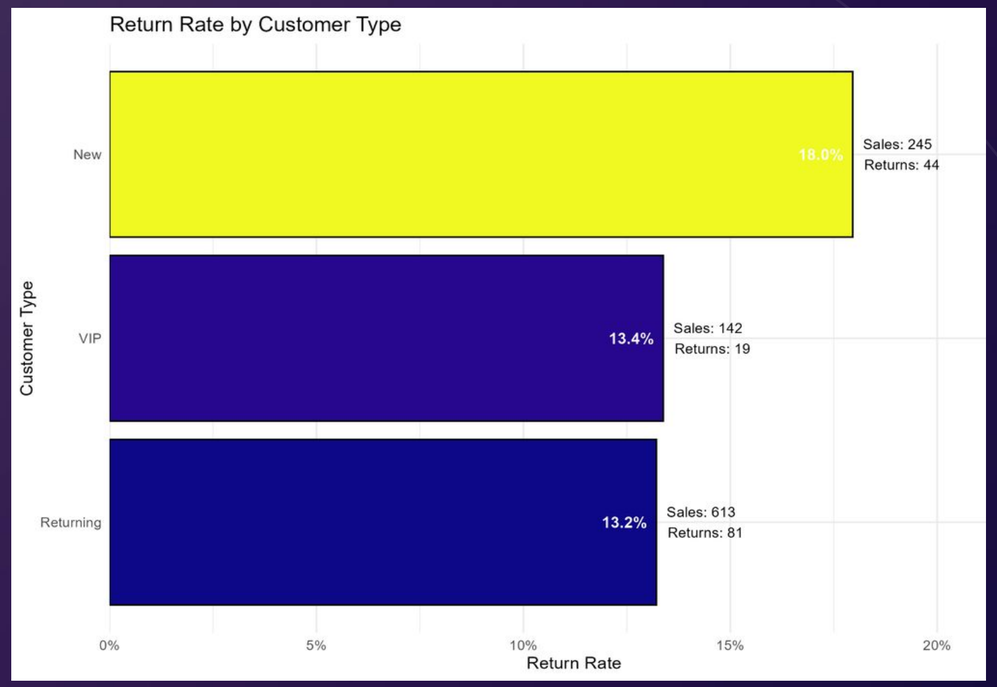

Bland **kategorier** har Fashion högst returgrad (16,2%), medan Sports har lägst (10,9%).

Regionalt sticker West ut med högst returgrad (18,8%), medan North har lägst (11,3%).

När det gäller **kundtyper** returnerar New customers oftare (18,0%) jämfört med Returning (13,2%) och VIP (13,4%).

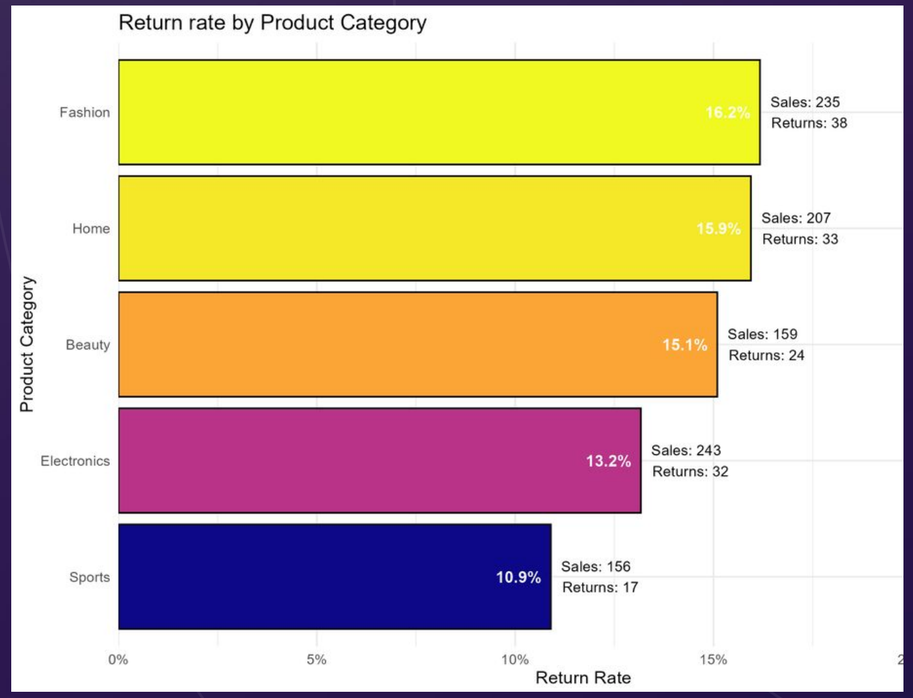

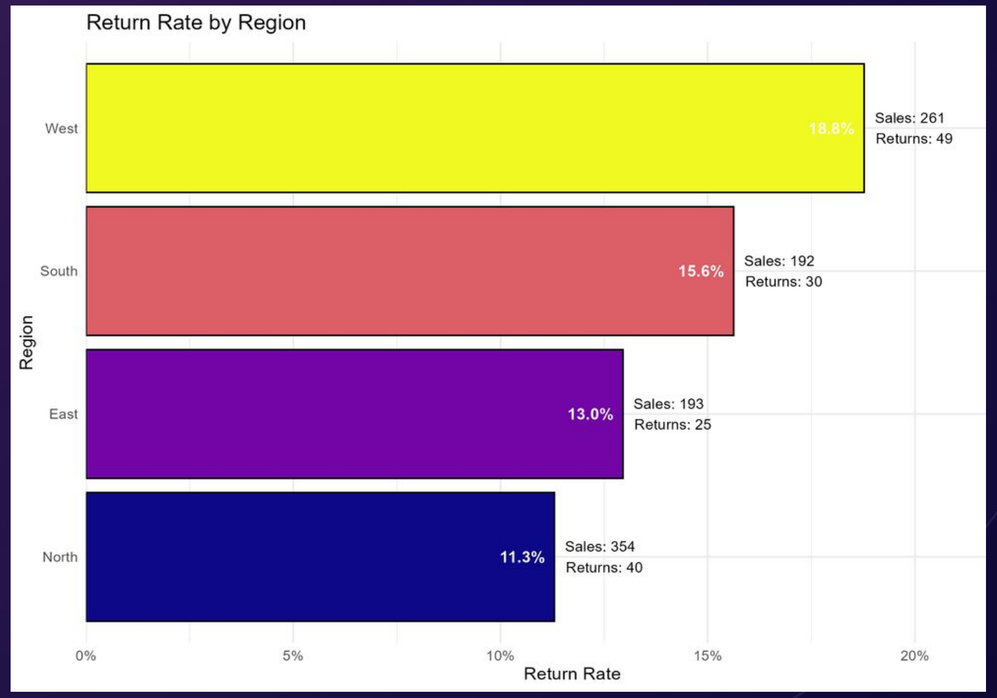

Ansvariga:
Kevin - Statistiska sammanfattningar
Anarkoli - Visualisering

Finns det tecken på att längre leveranstid hänger ihop med fler returer?

Det finns tecken på att längre leveranstid hänger ihop med fler returer.
Diagrammet visar returfrekvensen baserat på olika leveransgrupper. Det visar ett positivt samband mellan längre leveranstid och högre retur.

Kunder som inte returnerade sina ordrar hade i genomsnitt kortare leveranstid (3,55 dagar) jämfört med kunder som returnerade (3,98 dagar). Medianen visar samma mönster (3 dagar för “No” och 4 dagar för “Yes”).

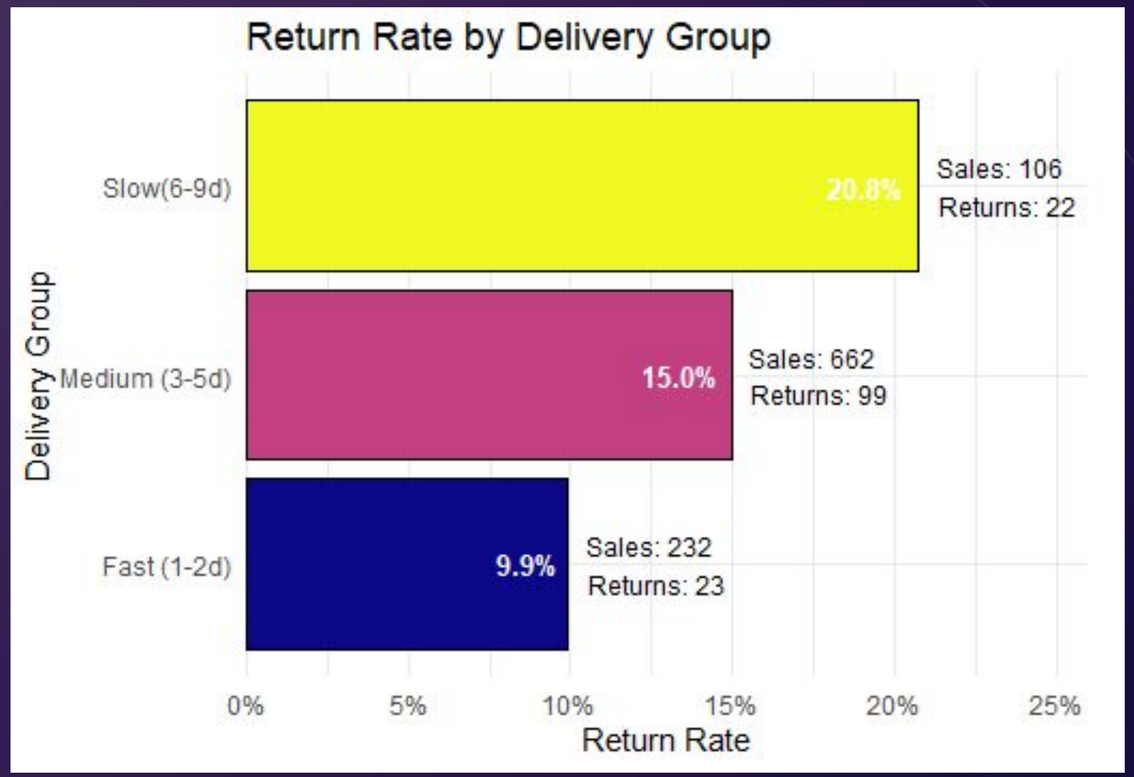

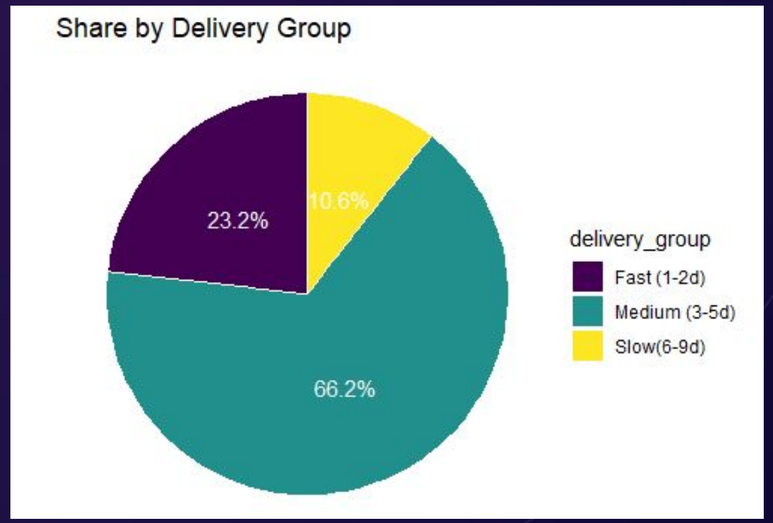

Ansvariga:
Kevin - Statistiska sammanfattningar
Anarkoli - Visualisering

Hur påverkar rabatter returgraden?

Resultatet visar ett tydligt mönster där returgraden ökar med högre rabatter.

Kunden utan rabatt (No discount) har den lägsta returgraden (9.4%), Låg rabatt (1–10%) visar en något högre returgrad (13.4%), Medium rabatt (11–25%) har en ännu högre returgrad (18.2%).Hög rabatt (25%+) har den högsta returgraden (50%), men detta resultat bör tolkas försiktigt eftersom antalet observationer i denna kategori är mycket litet (endast 4 ordrar).

Slutsatsen är att högre rabatter kan vara kopplade till ökad sannolikhet för avkastning.

En möjlig förklaring är att större rabatter kan locka mer impulsköp.

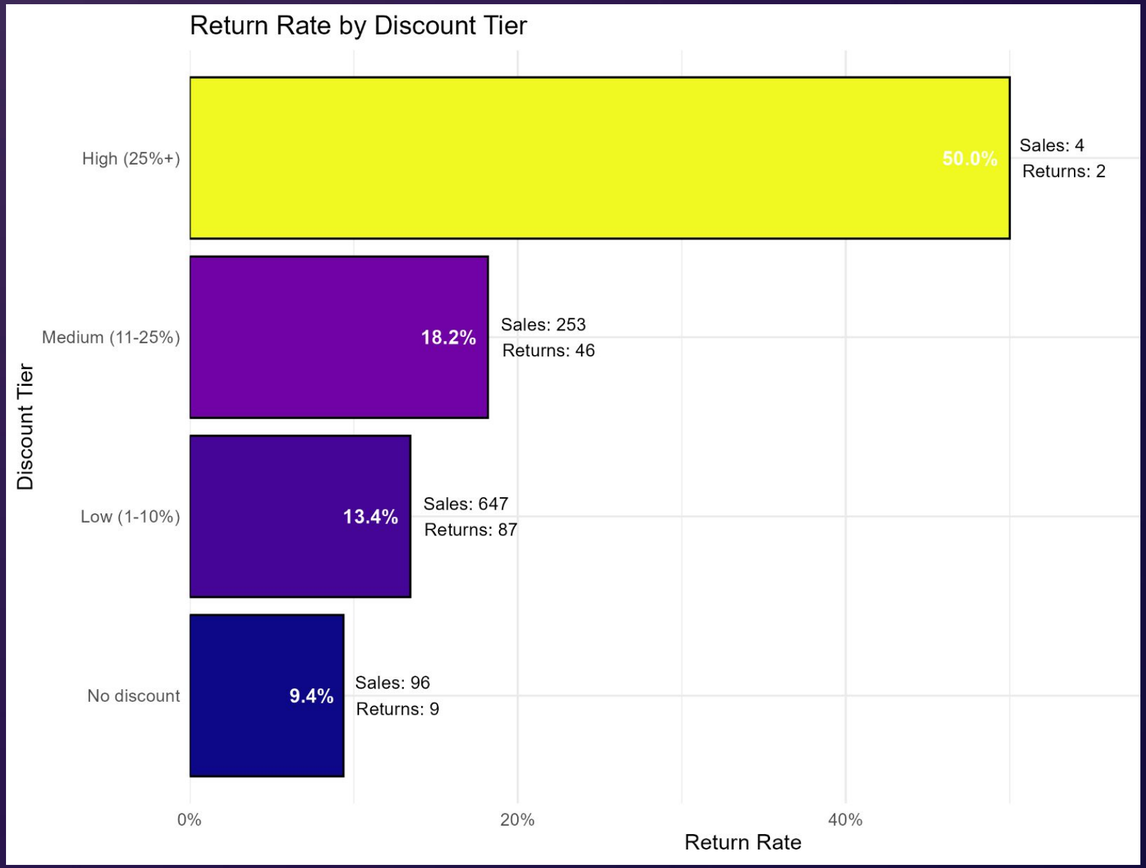

Slutsatser och rekommendationer

Slutsatser och rekommendationer
Analysen visar att returgraden varierar mellan olika produktkategorier, regioner och kundtyper. Fashion, kunder i region West och New customers har högre returgrad. Resultaten visar också ett samband mellan leveranstid och returer, där längre leveranstid hänger ihop med fler returer. Även lägre ordervärde och vissa rabattnivåer tycks kopplas till högre returgrad.

Företaget bör fokusera på att minska returer i kategorier med hög returgrad, särskilt Fashion. Det kan även vara viktigt att förbättra leveranstider, eftersom snabbare leverans verkar minska returer. Dessutom bör kampanjer och rabatter analyseras noggrannare för att undvika impulsköp som leder till returer.

Begränsningar och nästa steg
Analysen bygger på ett dataset med 1000 ordrar, vilket är relativt litet.

Nästa steg är att analysera större datamängder och undersöka fler faktorer som kan påverka returer, till exempel produktbeskrivningar eller kundbeteende.